

Efeito do Número de Memórias Recuperadas no A-Mem: uma Replicação Parcial com Desenho em Blocos no LoCoMo

Patrick de Ângelis Amâncio Meneses Santos
Programa de Pós-Graduação em Ciência da Computação (PPGCC)
Universidade Federal de Campina Grande (UFCG)
Campina Grande, Paraíba, Brasil

RESUMO

Este trabalho apresenta uma replicação parcial do método e dos artefatos do A-Mem. O experimento avalia o efeito de memórias recuperadas por consulta, $k \in \{3, 5, 10\}$, no primeiro diálogo do LoCoMo.

O limite de custo impediu o benchmark completo. O estudo fica condicionado a um diálogo com 19 sessões, 419 turnos e 199 perguntas, repetido em cinco blocos com ordem balanceada de k .

Em todos os blocos, $k = 10$ superou $k = 3$. O delta médio de F1 foi 0,0960, IC bootstrap de 95% [0,0806; 0,1136], teste exato de sinais unilateral $p = 0,03125$ e $d_z = 4,61$.

Os contrastes 3-5 e 5-10 foram positivos, mas inconclusivos após Holm. As durações registradas somaram 5,09 horas, sem o tempo da construção R1. O custo total é estimado em US\$2,52.

Código, dados, resultados, ambiente e hashes compõem o Kit de Reprodução. As conclusões não são generalizadas para o LoCoMo completo.

PALAVRAS-CHAVE

memória de agentes, LLM, A-Mem, LoCoMo, experimentação, reprodutibilidade

1 INTRODUÇÃO

Agentes baseados em grandes modelos de linguagem recuperam experiências anteriores para manter coerência. O A-Mem organiza essas experiências como notas interconectadas, inspirado no método Zettelkasten [3].

O LoCoMo é um dos benchmarks usados pelo A-Mem. Ele contém conversas extensas anotadas para resposta a perguntas e outras tarefas de memória [1].

O estudo original avalia dez diálogos, 1.986 perguntas, múltiplos modelos e baselines. Esse custo não era viável aqui.

Pela taxonomia adotada na disciplina, este trabalho é uma replicação parcial com extensão. Ele reutiliza código, dados e fluxo de avaliação, mas formula uma nova análise de sensibilidade de `retrieve_k`.

Adotou-se um estudo de caso: fixar o `sample 0`, reconstruir a memória cinco vezes e comparar três níveis de recuperação. Perguntas correlacionadas não são tratadas como réplicas independentes.

A questão principal é se recuperar dez memórias aumenta o F1 médio em relação a recuperar três. Contrastos 3-5 e 5-10, métricas secundárias, tokens, duração e custo são análises adicionais.

As contribuições são um desenho em blocos, instrumentação de uso e custo, análise estatística regenerável e um Kit de Reprodução que refaz a análise sem custo de API.

2 METODOLOGIA

2.1 Sistema, dados e escopo

O código-base é a implementação oficial do A-Mem, commit `0c8039f28fdc` [2]. Esse hash identifica o código upstream, não as modificações locais exatas usadas na coleta.

O backend foi a OpenAI API com `gpt-4o-mini`. O dataset tem SHA-256 iniciado por `79fa87e90f04`. O `sample 0` contém 19 sessões, 419 turnos e 199 perguntas.

O recorte é determinístico, não uma amostra aleatória dos dez diálogos. As categorias 1 a 5 seguem o mapeamento oficial: multi-hop, temporal, open-domain, single-hop e adversarial.

As análises por categoria são exploratórias. Há apenas um diálogo, e algumas categorias contêm poucos casos.

2.2 Desenho experimental

A variável independente é `retrieve_k`, com níveis 3, 5 e 10. Foram executadas cinco repetições separadas, R1 a R5. Cada repetição reconstruiu 419 memórias em cache próprio.

Dentro da repetição, os níveis compartilharam o cache. A agenda foi gerada antes da coleta com `schedule_seed` igual a 20260714 e depois incluída no manifesto.

A agenda ainda não estava em um commit Git antes da coleta. Os metadados dos 15 resultados confirmam a ordem executada. Cada nível apareceu uma ou duas vezes em cada posição.

O bloco, não a pergunta, é a unidade de repetição. As 199 perguntas são casos fixos e correlacionados dentro de um diálogo.

Seeds lógicas foram 20260715 a 20260719. Elas controlaram a agenda e geradores locais, mas não foram enviadas à OpenAI API. A temperatura foi 0,0 nas categorias 1-4 e 0,5 na adversarial.

2.3 Hipóteses e métricas

Para cada bloco r , definiu-se $d_r = F1_{r,k=10} - F1_{r,k=3}$. A hipótese nula é $P(d_r > 0) \leq 0,5$; a alternativa é $P(d_r > 0) > 0,5$, com $\alpha = 0,05$.

F1 médio foi o desfecho primário. Exact match, BLEU, ROUGE, METEOR e similaridades BERT/MBERT foram métricas secundárias. Categorias foram exploratórias.

Tokens, requisições, tentativas, falhas, duração e custo foram registrados por fase. Os preços por milhão de tokens foram US\$0,15 para entrada, US\$0,075 para cache e US\$0,60 para saída, em 14 de julho de 2026.

2.4 Plano de análise

O contraste primário usou teste exato de sinais unilateral. Com cinco deltas não nulos, a menor probabilidade unilateral é 0,03125. Os contrastes secundários usaram testes bilaterais e correção de Holm.

Reportam-se descritivas, diferença relativa, IC bootstrap de 95% com 10.000 reamostragens e d_z . Shapiro-Wilk é apenas diagnóstico; a decisão principal não depende de normalidade.

3 RESULTADOS

3.1 F1 por cenário e bloco

As médias de F1 foram 0,2676 (DP 0,0108) para $k = 3$, 0,2943 (DP 0,0165) para $k = 5$ e 0,3636 (DP 0,0177) para $k = 10$. A Tabela 1 resume os cenários.

Tabela 1: F1 médio entre os cinco blocos.

k	Média	DP	Blocos
3	0,2676	0,0108	5
5	0,2943	0,0165	5
10	0,3636	0,0177	5




Figura 1: F1 médio por bloco e valor de k no sample 0.

3.2 Contrastes pareados

Todos os cinco deltas 3–10 foram positivos. O ganho médio foi 0,0960, ou 35,9% da média-base. O IC bootstrap de 95% foi [0,0806; 0,1136].

O teste exato de sinais unilateral produziu $p = 0,03125$. Rejeita-se a hipótese nula no escopo condicionado às cinco repetições. O efeito foi $d_z = 4,61$, estimativa instável com $n = 5$.

Os deltas médios foram 0,0267 para 3–5 e 0,0693 para 5–10. Os testes bilaterais deram $p = 0,0625$ e $p_{Holm} = 0,125$. São evidências descritivas, não confirmações a 5%.

Shapiro-Wilk produziu $p = 0,146$, $p = 0,406$ e $p = 0,381$ para 3–5, 3–10 e 5–10. O diagnóstico tem baixo poder com $n = 5$ e não escolheu o teste principal.




Figura 2: Deltas pareados de F1 por bloco.

3.3 Métricas secundárias e categorias

Todas as métricas agregadas cresceram de $k = 3$ para $k = 10$. Por exemplo, exact match passou de 0,0935 para 0,1457; METEOR, de 0,1990 para 0,2731; e SBERT, de 0,4381 para 0,5274.

BLEU-1 foi coletado e preservado nos JSONs, embora não apareça na tabela compacta. Sua média entre blocos cresceu de 0,2346 em $k = 3$ para 0,2571 em $k = 5$ e 0,3184 em $k = 10$.

O F1 por categoria aumentou de $k = 3$ para $k = 10$ em multi-hop, temporal, single-hop e adversarial. Em open-domain, $k = 5$ obteve 0,1299 e $k = 10$, 0,1281. Esses resultados são exploratórios.

3.4 Custo, uso e tempo

As durações gravadas somaram 5,09 horas, mas não incluem a construção R1. Houve 11.067 requisições concluídas e nenhuma tentativa falha. O custo registrado foi US\$2,3567.

O total inclui quatro construções de memória, por US\$0,6515, e todas as avaliações. A construção R1 terminou antes de salvar telemetria. Pela média das outras quatro, o custo global estimado é US\$2,52.

Na avaliação, tokens médios foram 370.800, 652.939 e 1.278.731 para $k = 3, 5, 10$. Os respectivos custos foram US\$0,0549, US\$0,0970 e US\$0,1892.

Os DP de tokens foram 3.874, 14.769 e 34.551; os DP de custo, US\$0,0023, US\$0,0023 e US\$0,0060. Mais memórias elevaram uso e custo.

A duração total por execução inclui a construção na primeira posição do bloco. Portanto, diferenças de duração por k estão confundidas pela ordem e não recebem interpretação causal.

3.5 Comparação com o trabalho original

O estudo original compara A-Mem com baselines no LoCoMo completo e em vários modelos. Esta replicação preserva arquitetura, benchmark e fluxo de avaliação, mas não repete essa comparação ampla.

Aqui, a pergunta é uma análise de sensibilidade de retrieve_k em um diálogo e um modelo. O ganho com $k = 10$ mostra que a configuração de recuperação afeta o resultado local.

Esse achado não confirma a superioridade geral do A-Mem sobre baselines. Ele complementa o artigo original com evidência

Tabela 2: Contrastes pareados de F1 entre os cinco blocos.

Contraste	Delta médio	IC 95%	Dif. relativa	p	p_{Holm}	d_z
3-5	0,0267	[0,0162; 0,0409]	9,96%	0,0625	0,1250	1,59
3-10	0,0960	[0,0806; 0,1136]	35,87%	0,03125 unilateral	–	4,61
5-10	0,0693	[0,0556; 0,0867]	23,56%	0,0625	0,1250	3,34

Tabela 3: Médias entre blocos das métricas por cenário no LoCoMo sample 0.

k	Exact match	F1	ROUGE-1 F	METEOR	BERT F1	SBERT
3	0.093467	0.267630	0.279333	0.199038	0.894286	0.438117
5	0.110553	0.294297	0.305085	0.221730	0.897298	0.460274
10	0.145729	0.363631	0.374413	0.273141	0.907042	0.527424

condicionada e identifica custo maior quando mais memórias são recuperadas.

4 AMEAÇAS À VALIDADE

A ameaça externa dominante é o único diálogo. Os resultados não estimam desempenho médio no LoCoMo e não devem ser extrapolados para outros diálogos, modelos ou versões de API.

As 199 perguntas compartilham memória e contexto. Tratá-las como 199 réplicas independentes produziria inferência otimista.

Cinco blocos oferecem resolução limitada. O resultado atinge o menor p unilateral possível porque os cinco sinais são positivos. Isso sustenta a direção local, mas não substitui mais diálogos.

IC bootstrap e d_z são instáveis com cinco blocos. Devem ser interpretados junto aos deltas individuais.

As seeds não foram enviadas à API. Mesmo com temperatura controlada, respostas hospedadas não são bit a bit determinísticas. Mudanças de modelo ou infraestrutura podem afetar reproduções futuras.

Métricas automáticas podem penalizar respostas semanticamente equivalentes. Resultados por categoria têm poucos casos e são exploratórios.

Em R1, punkt_tab não estava no preflight. A falha ocorreu após salvar o cache e na primeira pergunta. A avaliação foi retomada sem reconstruir a memória.

O cache e os resultados foram preservados, mas tempo e uso da construção R1 ficaram ausentes. Nenhuma execução foi repetida ou excluída por desempenho.

O commit nos JSONs identifica o upstream. As mudanças locais usadas na coleta ainda não estavam commitadas, e a agenda não possuía comprovação Git anterior. Essa limitação retrospectiva não pode ser eliminada.

5 REPRODUTIBILIDADE E KIT DE REPRODUÇÃO

O Kit de Reprodução está no repositório público no GitHub, no commit 5b28c7a5c1b9. Depósito arquivístico e DOI permanecem pendentes.

O código-base usa MIT; o LoCoMo, CC BY-NC 4.0. Artigo, documentação e derivados locais usam CC BY 4.0, conforme LICENSE-ARTIFACTS.md.

O kit contém o código usado, ambiente travado, dataset, agenda, 15 JSONs, análise, testes, tabelas, figuras, protocolo e o artigo final em PDF e em fonte $\LaTeX$. A publicação do fonte permite inspecionar e recompilar o manuscrito, enquanto os resultados e ativos derivados permanecem rastreáveis pelo manifesto de hashes.

O ambiente foi macOS 26.4 arm64 em MacBook Pro com Apple M1 Pro, 10 núcleos, 16 GB de RAM e Python 3.11.15. Detalhes estão em docs/experimento-cinco-blocos/ambiente.md.

Após clonar o repositório indicado, os comandos abaixo instalam o ambiente, executam os testes públicos e regeneram análise e derivados:

```
cd amem
python3.11 -m venv .venv
. .venv/bin/activate
pip install -r requirements.lock.txt
python -m pytest tests -q
```

O README fornece os comandos completos para executar analyze_entrega3.py sobre os 15 JSONs e exportar tabelas e figuras. Esses passos não exigem chave nem custo de API.

Para refazer chamadas, configura-se .env.local. A execução paga exige o comando python run_entrega3.py --execute.

O runner não chama a API sem --execute. A agenda existente não é reescrita se divergir do plano. Somente JSONs completos, com 199 perguntas e metadados consistentes, são aceitos como válidos.

A coleta registrou 5,09 horas, acrescidas do tempo não registrado da construção R1. O custo total estimado é US\$2,52. Respostas futuras podem se aproximar, mas não coincidir bit a bit.

6 CONCLUSÕES

No sample 0, aumentar k de 3 para 10 elevou o F1 nas cinco repetições. O ganho médio foi 0,0960, com $p = 0,03125$. Contrastes intermediários foram inconclusivos após Holm.

Métricas secundárias acompanharam a direção do F1. Recuperar mais memórias também elevou tokens e custo de avaliação.

O resultado sustenta a hipótese condicionada ao diálogo, não uma afirmação sobre o LoCoMo completo nem sobre superioridade frente aos baselines originais.

A continuidade científica é repetir o desenho em mais diálogos. Dentro do limite financeiro, o projeto produz uma comparação sustentada, auditável e reproduzível.

REFERÊNCIAS

- [1] Adyasha Maharana, Dong-Ho Lee, Sergey Tulyakov, Mohit Bansal, Francesco Barbieri, and Yuwei Fang. 2024. Evaluating Very Long-Term Conversational Memory of LLM Agents. In *Proceedings of ACL 2024*, 13851–13870. <https://doi.org/10.18653/v1/2024.acl-long.747>
- [2] Wujiang Xu. 2025. A-Mem: Agentic Memory for LLM Agents – código oficial. <https://github.com/WujiangXu/A-mem>
- [3] Wujiang Xu, Zujie Liang, Kai Mei, Hang Gao, Juntao Tan, and Yongfeng Zhang. 2025. A-Mem: Agentic Memory for LLM Agents. In *Advances in Neural Information Processing Systems*. <https://doi.org/10.48550/arXiv.2502.12110>